Análisis de Datos

Trabajo Práctico Integrador — TMDB Movies Dataset

Autores: Juan Ignacio Trentalance & Leticia Lorena Rodríguez
Especialización en Inteligencia Artificial (CEIA / UBA)

1. MOTIVACIÓN Y ENFOQUE

El estudio aborda un análisis exploratorio de datos (EDA) profundo y el pipeline de preprocesamiento sobre más de 1.5 millones de registros de películas. El propósito final es sentar las bases para un modelo de regresión supervisado orientado a predecir la recaudación en taquilla (*Revenue*).

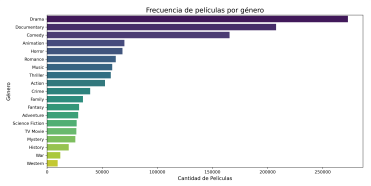
2. ESTRUCTURA Y LIMPIEZA DEL DATASET

1,514,263
REGISTROS BRUTOS

1,512,883
REGISTROS ÚNICOS (POST-DEDUPLICACIÓN)

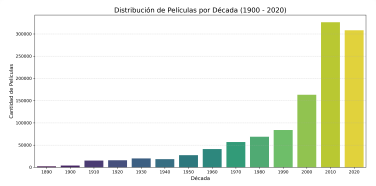
Se eliminaron 384 filas duplicadas exactas y 1,380 duplicados basados en el código de identificación único `id`.

3. DISTRIBUCIÓN POR GÉNERO



Volumen de películas distribuidas por categorías individuales.

4. TENDENCIA TEMPORAL



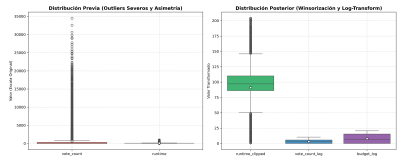
Crecimiento exponencial de producciones cinematográficas por década.

5. TRATAMIENTO DE OUTLIERS Y ESCALAS

Se aislaron valores atípicos masivos en presupuestos y 927 registros temporales fuera del rango histórico válido (1895–2026).



Asimetría severa en presupuestos.

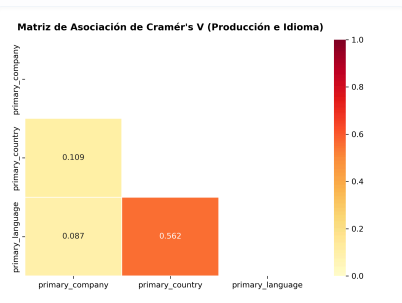


Efecto de Winsorización y Log-Transform.

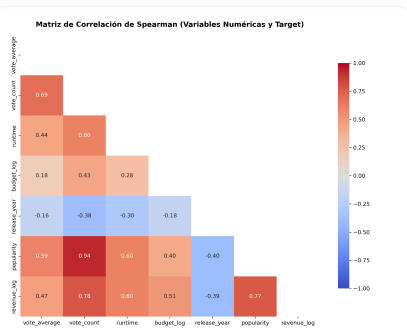
6. ESTRATEGIA DE VALORES FALTANTES

- **Eliminación de columnas:** Variables con >70% de nulos descartadas (`homepage`, `tagline`, `keywords`, `backdrop_path`).
- **Filas críticas:** Supresión de 20 filas sin título y 357,343 casos sin fecha de estreno con ingresos en cero.
- **Imputación Cruzada:** Explotación de dependencias cruzadas entre compañías y países productores.

7. ANÁLISIS DE RELACIONES Y CORRELACIONES



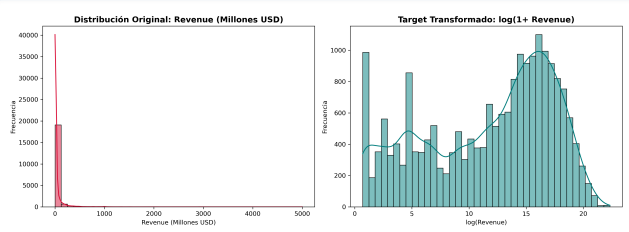
Asociación categórica (Cramér's V).



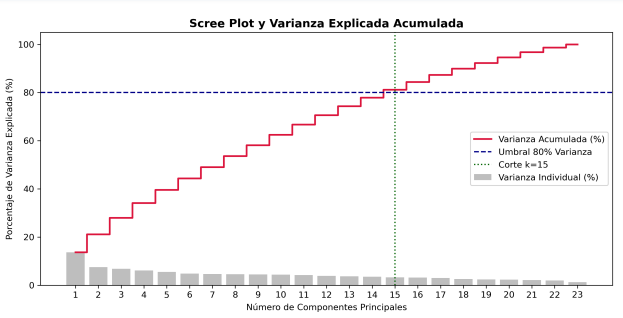
Correlación de Spearman hacia el Target.

8. PREPARACIÓN DE MACHINE LEARNING Y SPLIT (80-20)

Definición del Problema: Modelo de Regresión Supervisado para predecir `revenue` (recaudación positiva procesada logarítmicamente para normalizar su distribución). Tras el filtrado, se obtuvo un total de 25,587 filas válidas divididas en **Train:** 20,469 registros (80%) y **Test:** 5,118 registros (20%) con mezcla aleatoria (`shuffle=True`).



Normalización del Target mediante transformación logarítmica.



Reducción de dimensionalidad y análisis de componentes principales (PCA).

9. FEATURE SELECTION Y DATASET FINAL

Mediante ingeniería de características, codificación de variables categóricas (géneros, idiomas, estudio principal) y el análisis de componentes principales (PCA), se seleccionó el conjunto definitivo de variables optimizadas para evitar la multicolinealidad y mejorar la generalización del algoritmo predictivo.

Estructura del Dataset Final:

Característica (Feature)	Tipo de Dato	Descripción / Transformación Aplicada
`vote_count_log`	float64	Transformación logarítmica de la cantidad de votos (alta correlación con el éxito comercial).
`budget_log`	float64	Presupuesto de producción transformado logarítmicamente.
`runtime_clipped`	float64	Duración en minutos depurada de outliers severos mediante recorte (Clipping).
`release_year`	float64	Año de estreno extraído de la fecha oficial de lanzamiento.
`is_major_studio`	float64	Indicador binario si pertenece a un estudio de producción principal.
`genre_drama`, `genre_comedy`, `genre_action`, `genre_thriller`, `genre_adventure`, `genre_horror`, `genre_romance`, `genre_crime`, `genre_science_fiction`, `genre_family`	float64	Variables one-hot/binarias para los géneros cinematográficos seleccionados.
`month_sin`, `month_cos`	float64	Codificación cíclica (seno y coseno) de la estacionalidad del mes de estreno.
`has_poster`	float64	Variable binaria que indica la disponibilidad de póster visual.
`lang_es`, `lang_fr`, `lang_pt`, `lang_zh`, `lang_other`	float64	Variables agrupadas y codificadas por idioma original predominante.
`revenue (Target)`	float64	Variable objetivo transformada con log(1 + revenue) para estabilizar la varianza en la regresión.